# Çok Modlu Ürün Kategori Sınıflandırma

Ürün Adı ve Ürün Görselinin Birlikte Kullanılması

**Nurgül Sarıtaş**

Bursa Teknik Üniversitesi
Bilgisayar Mühendisliği, 4. sınıf

TÜBİTAK Proje Ekibi Ön Değerlendirme Ödevi

Prof. Dr. Turgay Tugay Bilgin

Ekim 2026

## İçindekiler


**1 Giriş** **1**

**2 Veri ve Ön İşleme** **1**

2.1 Veri Seti ve Temizleme . . . . . 1

2.2 Keşifsel Veri Analizi . . . . . 1

2.3 Veri Bölme . . . . . 1

**3 Yöntem** **2**

3.1 Metin Modeli . . . . . 2

3.1.1 TF-IDF ve Sınıflandırıcılar . . . . . 2

3.1.2 Maskeleme . . . . . 2

3.2 Görsel Model . . . . . 2

3.2.1 Transfer Öğrenme ve Görsel Hazırlığı . . . . . 2

3.2.2 İki Aşamalı Eğitim . . . . . 2

3.3 Füzyon . . . . . 2

**4 Deneyler ve Bulgular** **2**

4.1 Metin Modeli . . . . . 2

4.2 Görsel Model . . . . . 3

4.3 Füzyon ve Test Sonuçları . . . . . 3

4.4 Hata Analizi . . . . . 3

4.5 Modelin Yorumlanması ve Demo . . . . . 4

**5 Tartışma** **4**

**6 Sonuç** **5**

**Kaynaklar** **5**

# 1 Giriş

E-ticaret sitelerinde binlerce ürün satıcılar tarafından yükleniyor ve her ürünün doğru kategoriye girmesi gerekiyor. Bu projede bunu otomatik yapmaya çalıştım: Bir ürünün kategorisini (`articleType`, en sık 20 sınıf) yalnızca **adına** ve **fotoğrafına** bakarak tahmin eden modeller kurdum. Satıcıların yazdığı adlar her zaman açık olmuyor. Telefonda birine "Lino Perros marka, siyah, deri bir şey" derseniz bunun kemer mi cüzdan mı olduğunu anlayamaz ama bir fotoğraf her şeyi çözer. Bu yüzden asıl cevabını aradığım soru şuydu: *Ürün adı yetersiz kaldığında fotoğraf bu açığı ne kadar kapatabiliyor?*

**Amaç ve kapsam:** Metin ve görselin tek başına ve birlikte ne kadar başarılı olduğunu ölçmek istedim. Bunun için bir metin modeli (TF-IDF + lojistik regresyon / doğrusal SVM) ve bir görsel model (EfficientNetB0 ile transfer öğrenme) eğittim, ikisini iki farklı yöntemle birleştirdim ve deneyleri hem orijinal hem de sınıf adları silinmiş (maskelenmiş) ürün adlarıyla tekrarladım. Ayrıca görsel modelin karar verirken nereye baktığını Grad-CAM ile inceledim ve modelleri denemek için bir Gradio demosu hazırladım. Kısaca sonuç: Ad sınıfı açıkça söylediğinde görsel neredeyse hiç katkı sağlamadı, ad zayıfladığında ise başarıyı yaklaşık 13 puan artırdı.

Çalışma boyunca bütün seçimleri (model, ayar, ağırlık) **doğrulama kümesine** bakarak yaptım; **test kümesini** her model için yalnızca bir kez, en sonda kullandım. Test kümesine bakarak ayar yapmak, sınav sorularını önceden görüp ona göre çalışmak gibi olurdu. Çalışmayı Google Colab'da scikit-learn ve TensorFlow/Keras ile yaptım.

# 2 Veri ve Ön İşleme

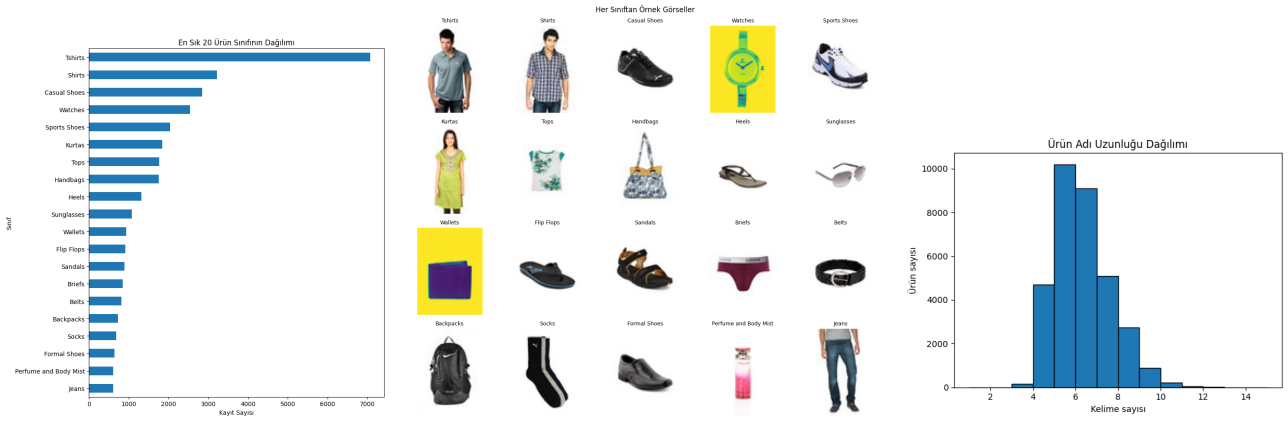
## 2.1 Veri Seti ve Temizleme

Kaggle'daki *Fashion Product Images (Small)* veri setinde 44.446 ürün ve 60×80 piksellik görselleri var. Model girdisi olarak yalnızca ürün adını ve görseli kullandım. `subCategory`, `gender` gibi sütunları hiç kullanmadım, çünkü cevabı doğrudan veriyorlar: `subCategory` değeri "Watches" olan ürünlerin hepsi Watches sınıfında. Bunu modele vermek, cevap anahtarı kâğıdın arkasına yazılmış bir sınava girmek gibi olurdu (*etiket sızıntısı*).

Temizlikte üç şey yaptım. Ürün adında tırnaksız virgül olduğu için bozuk okunan 22 satırı silmek yerine **onardım**, çünkü bu ürünlerde bir sorun yoktu ve veri kaybetmek istemedim. Adı geçersiz olan 9 kaydı ("NA" gibi) ve görseli olmayan 5 kaydı çıkardım, çünkü bunlar en az bir modelde kullanılamıyordu. "Playboy" gibi kısa ama gerçek adları ise tuttum; kuralım **geçersizi çıkar, zoru tut** oldu, çünkü zor örnekleri atmak modeli olduğundan başarılı gösterirdi. Sonra en sık 20 sınıfı seçtim ve elimde **33.142 ürün** kaldı.

## 2.2 Keşifsel Veri Analizi

Sınıflar oldukça dengesiz: En büyük sınıf Tshirts (7.069), en küçüğü Jeans'ten (608) yaklaşık **11,6 kat** büyük (Şekil 1a). Doğruluk her ürünü eşit saydığı için büyük sınıflar sonucu domine eder. **Makro-F1** ise her sınıfın F1 değerinin ortalamasını alıyor, yani her sınıfı eşit sayıyor; bir öğretmenin bütün öğrencilerin ortalaması yerine her şubenin ortalamasına ayrı ayrı bakması gibi. Bu yüzden birincil ölçüt makro-F1. Görseller çok küçük ve Flip Flops ile Sandals gibi bazı sınıflar birbirine çok benziyor (Şekil 1b). Ürün adları ortalama 5,8 kelime ve sınıf adı genellikle son kelime (Şekil 1c).




**(a)** Sınıf dağılımı

**(b)** Her sınıftan örnek görsel

**(c)** Ürün adı uzunluğu (kelime)

**Şekil 1:** Keşifsel veri analizi.

## 2.3 Veri Bölme

Veriyi **tabakalı** olarak ve **sabit tohumla** (42) %70 / %15 / %15 oranında böldüm: 23.199 / 4.971 / 4.972 ürün. Tabakalı bölme her sınıfın oranını üç kümede aynı tutuyor; sabit tohum ise bölmenin her çalıştırmada aynı çıkmasını sağlıyor. Bölmeyi `split.csv` olarak kaydettim ve bütün modellerde aynısını kullandım. Kontrol ettiğimde test kümesindeki farklı ürün adlarının **%31,9'unun** eğitimde de geçtiğini gördüm. Model bu adları ezberden bilebileceği için sonuç biraz iyimser çıkabilir. Aynı ürünün farklı renk ve bedenleri gerçek bir katalogda da sık görüldüğü için bölmeyi değiştirmedim; bunun

yerine bu etkinin büyüklüğünü ayrıca ölçtüm (Bölüm 4.1).

# 3 Yöntem

## 3.1 Metin Modeli

### *3.1.1 TF-IDF ve Sınıflandırıcılar*

Modeller metni okuyamadığı için ürün adlarını **TF-IDF** ile sayılara çevirdim. TF-IDF her üründe geçen "Men", "Black" gibi kelimelere düşük, "Watch", "Kurta" gibi ayırt edici kelimelere yüksek ağırlık veriyor: Herkesin giydiği forma kimseyi tanıtmaz ama "kırmızı gözlüklü" tanıtır. Sınıflandırıcı olarak **lojistik regresyon** (LR) ve **doğrusal SVM** kullandım. **Nasıl seçtim?** Üç TF-IDF ayarı (varsayılan, tek harfleri koruyan ve kelimeleri 2–5 harflik parçalara bölen *karakter TF-IDF*), iki model ve üç $C$ değeriyle 18 deneme yapıp doğrulama kümesinde karşılaştırdım. TF-IDF'i yalnızca eğitim kümesiyle öğrettim; aksi halde test kümesinin bilgisi modele sızardı.

### *3.1.2 Maskeleme*

Sınıf adlarını ürün adlarından silip modeli yeniden eğittim (ör. "Turtle Check Men Navy Blue Shirt" $\rightarrow$ "Turtle Check Men Navy Blue"). Bu, eksik başlıkla gelen ürünleri taklit ediyor. **Nasıl?** Önce adların nasıl yazıldığına baktım; Tshirts için "T-shirt", "Tshirt" gibi farklı yazımlar vardı. Sınıf adı kelimelerini tekil, çoğul ve tireli biçimleriyle düzenli ifadeyle, yalnızca tam kelime olarak sildim. "flats", "polo" gibi eş anlamlıları bilerek eklemedim, çünkü amaç yalnızca sınıf adının etkisini ölçmekti ve eş anlamlılarda nerede duracağıma dair tutarlı bir sınır çizmek mümkün değildi.

## 3.2 Görsel Model

### *3.2.1 Transfer Öğrenme ve Görsel Hazırlığı*

Keras'ta ImageNet'te önceden eğitilmiş **EfficientNetB0** ile transfer öğrenme yaptım. **Neden?** Sıfırdan bir görüntü modeli eğitmek çok fazla görsel ister; elimde 23 bin eğitim görseli vardı. ImageNet'te eğitilmiş bir ağ kenar, doku ve şekil tanımayı zaten biliyor; yıllarca resim yapmış birine moda çizimi öğretmek, sıfırdan başlayan birine öğretmekten çok daha kolaydır. **Giriş boyutu neden 128$\times$128?** Görselleri 224$\times$224'e büyütmek yeni bilgi eklemeden işlemi yaklaşık 3 kat yavaşlatırdı; çok küçük bırakmak ise ağın son katmanlarında ayrıntı bırakmazdı. Görselleri esnetmeden büyütüp kenarlarını beyazla doldurdum. Eğitimde görselleri rastgele çevirip döndürdüm (*veri artırma*); böylece model ezberlemek yerine ürünü tanımayı öğreniyor.

### *3.2.2 İki Aşamalı Eğitim*

Önce ağın gövdesini dondurup yalnızca üstüne eklediğim 20 sınıflık katmanı eğittim; yeni katman başta rastgele olduğu için gövdeyi baştan açsaydım ImageNet'ten gelen bilgi bozulabilirdi. Sonra gövdenin son 30 katmanını açıp **100 kat düşük** öğrenme oranıyla ince ayar yaptım. Düşük öğrenme oranı, neredeyse akortlu bir gitarın burgularını çok az çevirmek gibi: Öğrenilmiş bilgi küçük adımlarla değişiyor. Aşırı öğrenmeyi önlemek için EarlyStopping, en iyi modeli kaydetmek için ModelCheckpoint kullandım.

## 3.3 Füzyon

**Geç füzyon:** İki model ayrı ayrı tahmin yapıyor, olasılıkları $p = w\,p_{\text{metin}} + (1-w)\,p_{\text{grsel}}$ ile birleştiriliyor; biri tahlile diğeri röntgene bakan iki doktorun görüşlerinin ağırlıklı ortalaması gibi. $w$'yi doğrulama kümesinde 0'dan 1'e 0,05 adımla deneyerek seçtim. Metin modeli olarak olasılık verebildiği için LR'yi kullandım.

**Ara füzyon:** Burada doktorlar notlarını masaya koyup birlikte karar veriyor. TF-IDF 41.680 sütun ürettiği için metni TruncatedSVD ile 256 sayıya sıkıştırdım; aksi halde metin, görsel modelin 1.280 sayılık özetini ezerdi. İkisini yan yana koyup aynı ölçeğe getirdim ve küçük bir Keras MLP eğittim. Füzyondan önce metin ve görsel dosyalarındaki ürün sırasının aynı olduğunu kontrol ettim.

# 4 Deneyler ve Bulgular

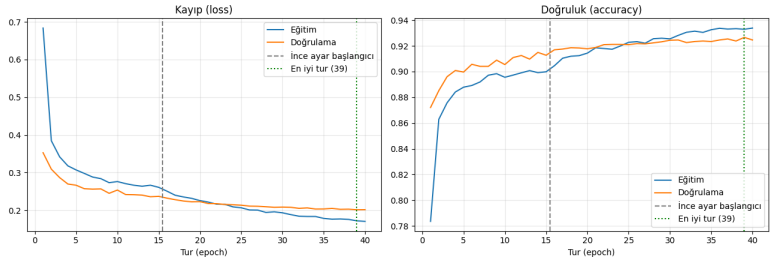
## 4.1 Metin Modeli

En iyi sonucu **karakter TF-IDF + LR ($C = 10$)** verdi (doğrulama makro-F1: 0,9875). **"T-shirt" sorunu:** İlk denemede en sık hata Shirts $\rightarrow$ Tshirts idi. Varsayılan TF-IDF "T-shirt" kelimesindeki tek harfli "t"yi attığı için iki sınıf model için aynı "shirt" kelimesine dönüşüyordu. Tek harfleri koruyunca Shirts F1 değeri **0,906'dan 0,996'ya** çıktı; karakter TF-IDF de bu sorunu kendiliğinden çözüyor.

**Maskeleme:** Doğrulama makro-F1 değeri **0,9875'ten 0,8206'ya** düştü; yani başarının büyük kısmı sınıf adını okumaktan geliyordu. En çok Belts ve Wallets zorlandı, çünkü aynı markalar hem kemer hem cüzdan üretiyor. **Ezber etkisi:** Adı eğitimde görülmüş test ürünlerinde makro-F1 0,994, görülmemişlerde 0,975 çıktı; maskeli adlarda fark yaklaşık 7 puana büyüdü. Yani ezber etkisi var ama yeni adlarda da başarı yüksek.

### 4.2 Görsel Model

İnce ayarın sonunda doğrulama kaybı hâlâ düştüğü için eğitimi 15 tur uzattım; en iyi model 39. turda geldi. Son turlarda eğitim kaybı düşerken doğrulama kaybı durağanlaştı (Şekil 2); bunu aşırı öğrenmenin başladığının işareti olarak yorumlayıp en iyi turdaki modeli kullandım. Görsel model testte **0,9251** makro-F1 aldı. Ayakkabılarda zorlandı ama maskeli metnin zorlandığı Belts (0,996) ve Wallets (0,965) sınıflarında çok başarılıydı; yani iki model birbirinin zayıf noktasında güçlüydü.




**Şekil 2:** Görsel modelin eğitim eğrileri. Gri çizgi ince ayarın başlangıcını, yeşil çizgi en iyi turu (39) gösterir.

### 4.3 Füzyon ve Test Sonuçları

Doğrulama kümesinde seçilen ağırlık orijinal adlarda $w = 0{,}55$, maskeli adlarda $w = 0{,}50$ oldu; metin zayıflayınca görsele daha fazla güvenmek mantıklı. Ara füzyonda MLP çok hızlı öğrendiği için EarlyStopping onu 7–8. turda durdurdu. Test sonuçları Tablo 1'de. Testte SVM, LR'yi çok küçük bir farkla geçti ama seçimi doğrulama kümesine göre yaptığım için LR'de kaldım ve test sonucunu gördükten sonra hiçbir ayarı değiştirmedim.

| No | Model | Ürün adı | Doğruluk | Makro-F1 |
|---|---|---|---|---|
| 1 | TF-IDF + lojistik regresyon | Orijinal | 0,9843 | 0,9821 |
| 2 | TF-IDF + doğrusal SVM | Orijinal | 0,9849 | 0,9835 |
| 3 | En iyi metin modeli (LR) | Maskelenmiş | 0,8407 | 0,8172 |
| 4 | Keras transfer öğrenme (yalnızca görsel) | Kullanılmıyor | 0,9204 | 0,9251 |
| 5 | Geç füzyon ($w = 0{,}55$) | Orijinal | 0,9871 | **0,9850** |
| 6 | Geç füzyon ($w = 0{,}50$) | Maskelenmiş | 0,9491 | **0,9535** |
| 7 | Ara füzyon | Orijinal | 0,9773 | 0,9755 |
| 8 | Ara füzyon | Maskelenmiş | 0,9395 | 0,9445 |

**Tablo 1:** Test kümesi sonuçları. Bütün seçimler doğrulama kümesinde yapılmıştır.

**Görselin katkısı:** Görselin katkısını "füzyon − metin tek başına" olarak hesapladım. Orijinal adlarda katkı geç füzyonda +0,30, ara füzyonda −0,65 puan; maskeli adlarda ise geç füzyonda **+13,62**, ara füzyonda **+12,72** puan.

### 4.4 Hata Analizi

En iyi model (geç füzyon, orijinal ad) 4.972 test ürününden 64'ünü yanlış sınıflandırdı. Sınıflar dengesiz olduğu için karışıklık matrisinin her satırını kendi toplamına böldüm (Şekil 3a). En çok karışan beş çiftin hepsi ayakkabı ve terlik sınıflarıydı ve hataların **%69'unu** oluşturuyordu; en sık hata Casual → Sports Shoes (14). Sınıf bazlı F1'de de en düşük sınıflar bunlardı (ör. Formal Shoes 0,938).




**(a)** Normalize karışıklık matrisi

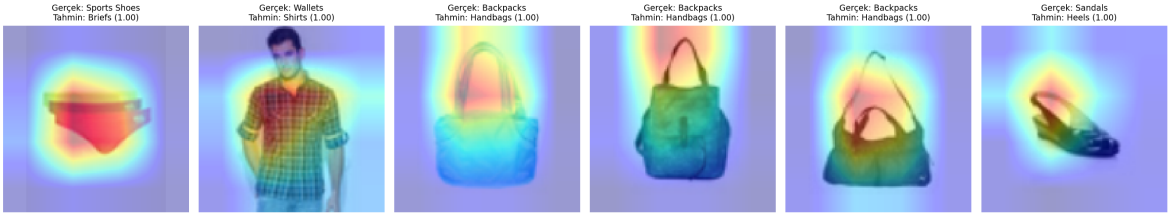
**(b)** En emin olunan 16 hata (yeşil: gerçek, kırmızı: tahmin)

**Şekil 3:** Geç füzyon (orijinal ad) modelinin test kümesindeki hataları.

Modelin en emin olduğu 16 hatayı görselleriyle inceledim (Şekil 3b). Bazılarında model haklıydı: “Puma Women Ikonis 2 White Sports Shoes” adlı ürün Casual Shoes etiketliydi, model ise Sports Shoes dedi. Bu örneklere bakınca “hataların çoğu etiket hatası” diye düşündüm. **Bunu nasıl sınadım?** 64 hatanın tamamını ürün adına bakan basit bir kuralla grupladım: Hataların **%78’inde** ad türü söylemiyordu (ör. “Red Tape Men Brown Shoes”), **%17’si** olası etiket hatasıydı ve yalnızca 2 hata gerçek model hatasıydı. Buradan, birkaç dikkat çekici örneğe bakıp genelleme yapmamam gerektiğini öğrendim.

### 4.5 Modelin Yorumlanması ve Demo

**Grad-CAM:** Model doğru tahmin etse bile yanlış bir yere bakıyor olabilir. Bunu görmek için TensorFlow’un gradyan hesaplama aracıyla Grad-CAM ısı haritalarını kendim oluşturdum. Doğru tahminlerde model ürünün ayırt edici parçasına bakıyor: saatte kadrana, gözlükte camlara. Yanlış tahminlerde ise saplı sırt çantalarının Handbags sanıldığını ve haritanın her birinde **sapı** gösterdiğini gördüm (Şekil 4); model “Handbags” kararını büyük ölçüde sapa bakarak veriyor.




**Şekil 4:** Görsel modelin en emin olduğu 6 hata için Grad-CAM haritaları. Saplı sırt çantalarında model sapa bakıyor.

**Gradio demosu:** Görsel yükleyip ürün adı yazınca sınıf olasılıklarını gösteren bir demo hazırladım; demo yalnızca görselle, yalnızca adla ya da ikisi birlikte (geç füzyon) çalışıyor. Bir denemede tişört görseli tek başına Tshirts %92, “. . . White Top” adı tek başına Tops %100 dedi; ikisi birlikte verilince sonuç Tops %58, Tshirts %42 çıktı. İki model çelişince geç füzyon ağırlığa göre karar veriyor.

## 5 Tartışma

**Görselin katkısı neden değişiyor?** Ad sınıfı açıkça söylediğinde metin modeli zaten %98’in üzerinde başarılı ve görselin ekleyecek bir şeyi kalmıyor. Ad zayıfladığında ise görsel, kemer ve cüzdan gibi metinde benzeyen ama görselde çok farklı olan sınıflarda açığı kapatıyor. Ayakkabılarda iki kaynak da zayıf olduğu için füzyon bile hataları tamamen çözemiyor.

**Ara füzyon neden geride kaldı?** SVD sıkıştırmasında metin bilgisinin yaklaşık dörtte biri kayboluyor ve MLP birkaç turda ezberlemeye başlıyor. Geç füzyonda ise metin modeli TF-IDF’in tamamını kullanıyor.

**Türkçe bir kataloğa uygulama:** Türkçe eklemeli bir dil; “ayakkabı”, “ayakkabılar”, “ayakkabısı” gibi biçimler çok. Karakter TF-IDF ortak harf parçalarını yakaladığı için burada avantajlı olabilir ama maskeleme çok daha zor olurdu, çünkü her sınıf adının bütün ekli biçimlerini listelemek gerekirdi. “kadın”/“kadin” gibi farklı yazımlar, “I”/“ı” dönüşümü ve Türkçe–İngilizce karışık adlar da ek sorunlar yaratır.

**Sınırlılıklar:** Test adlarının bir kısmı eğitimde de geçtiği için sonuçlar biraz iyimser; grup bazlı bir bölme bunu önleyebilirdi. Maskeleme eş anlamlıları kapsamıyor, veride etiket hataları var ve geç füzyonda ağırlık her ürün için sabit.

## 6 Sonuç

Ürün adı ve görselini birlikte kullanan bir kategori sınıflandırma sistemi geliştirdim. En iyi sonucu geç füzyon verdi (orijinal adlarla 0,985, maskeli adlarla 0,954 makro-F1). Temel bulgu, görselin katkısının ürün adının gücüne bağlı olması: Başlıkları düzgün bir katalogda görsel model ek maliyetine değmeyebilir ama satıcıların eksik başlıklarla ürün yüklediği bir pazaryerinde çok değerli hale gelir. Bu çalışma bana, “T-shirt” örneğindeki gibi küçük bir ayrıntının sonucu ne kadar değiştirebileceğini ve yüksek bir başarı oranının her zaman modelin gerçekten öğrendiği anlamına gelmediğini gösterdi.

## Kaynaklar


1. P. Aggarwal, *Fashion Product Images (Small)*, Kaggle, `https://www.kaggle.com/datasets/paramaggarwal/fashion-product-images-`
2. M. Tan, Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”, *ICML*, 2019.
3. J. Deng vd., “ImageNet: A Large-Scale Hierarchical Image Database”, *CVPR*, 2009.
4. R. R. Selvaraju vd., “Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization”, *ICCV*, 2017.